

受内存约束的 MoE 推理中“慢介质读一次”下界及其真机验证

作者姓名

作者单位, 省份 城市 邮编; 作者职称、研究方向占位

收稿日期: 2026-××-×× 基金项目: ×××× (编号 ×××××××)

第一作者: ×××, ×× (职称), 主要研究方向为×××; 邮箱: xxx@xxx.xxx (通讯作者)

中图分类号: TP3 文献标志码: A

摘要: 混合专家 (Mixture-of-Experts, MoE) 模型凭借稀疏激活降低单 token 计算量, 但推理瓶颈在有内存约束的设备 (如仅有系统内存、需从机械盘流式读权重的主机) 上往往不是计算, 而是权重的搬运。本文以 2.8T 参数开源模型 Kimi K3 的真机推理为对象, 报告一个普遍但常被忽略的结构事实: 当被激活的专家权重无法常驻最快介质层时, 每个 token 都必须从慢介质全量重读一遍。本文给出并证明了“慢介质读一次”定理——若数据 d 的复用发生在 d 能到达的最快介质层 M_k 上, 则对任意更慢介质层 M_i ($i < k$), 读取次数恒有 $R_i \geq 1$, 且该下界同时可达: 存在调度使每个慢层恰好读一次, 其余 $R-1$ 次复用全部落在 M_k 上; 该调度同时是慢访问代价最小的调度。真机台账 (k3 x86, 2026-08 冷启动) 显示: 每 token 专家段从慢盘重读 25.83 GB, 耗时 303.58 s, 占端到端 94%。对照实验进一步量化了“复用未落进最快层”时的代价: 将专家全量放入 L2 介质驻留缓存, 专家段耗时降至 191.6 s (约 -37%)。本文的定理是逻辑命题, 可无条件迁移; 真机数字只对本实验成立, 供识别同类带宽墙使用。

关键词: 混合专家模型; MoE 推理; 存储层次; 带宽墙; 缓存调度; Roofline 模型

1 引言

1.1 背景

大语言模型的规模扩张已进入万亿参数量级, MoE 因其稀疏激活特性成为主流扩展范式[1-6]。以 Kimi K3 为例[1]: 共 93 层、总参数约 2.8T, 采用 896 路由专家的 Stable LatentMoE, 每 token 仅激活 16 个专家, 激活参数约 104B。单看稀疏红利, 每个 token 只需读取全部专家权重的约 1.8%, 这是 MoE 推理“省带宽”承诺的由来。

但该承诺有一个常被忽略的隐藏前提: 被激活的权重必须常驻在或能快速到达计算侧。在 GPU 服务器上, trunk 与热专家常驻显存, 该前提成立; 而在仅配有系统内存、硬盘, 甚至需要从机械盘流式读权重的主机/边缘设备上, 前提不成立——此时“稀疏”只减少了必须搬动的字节总量, 却没有改变“这些字节要从哪一层介质搬”这一结构问题。

1.2 现象与动机

本文工作源于一次真机碰壁。在一台 k3 x86 主机上以冷启动方式跑 Kimi K3 推理, 运行时字节流台账显示: 每 token 专家段从慢盘读取 25.83 GB, 以约 85 MB/s 计耗时 303.58 s, 占端到端 324.36 s 的 94%[13]。也就是说, 模型虽然每 token 只“激活”约 25.8 GB 专家权重, 引擎却让它们每 token 从慢介质全量重读一遍——慢介质读的绝不是一次, 而是每 token 一次。

这个现象促使本文回答两个问题：（1）一个数据项只在慢层各读一次、其余复用全部发生在最快层，是否总是可行？其理论下界是什么？（2）该下界在真机上是否可被观测、可被回查？

1.3 本文贡献

- ① 形式化“慢介质读一次”定理：给出读取下界 $R_i \geq 1$ 、其可达性构造与“慢访问代价最小”的最优性证明（第3章）；
- ② 提供可逐字节回查的真机字节流台账及其与定理的对应关系（第4章）；
- ③ 给出可迁移的工程判据：识别受内存约束 MoE 推理瓶颈的第一步是确认“复用是否落在数据能到达的最快介质层”（第5章）。

2 相关工作

2.1 MoE 架构与稀疏化

MoE 的思想可追溯到 Shazeer 等的稀疏门控网络[2]，GShard[3] 提出 top-K 路由与分片；Switch Transformer[4] 进一步把激活专家降至单个；Mixtral of Experts[5] 证明开源 $8 \times 7B$ 级 MoE 的实用性；DeepSeekMoE[6] 提出细粒度专家切分与共享专家隔离，Kimi K3[1] 在其基础上的 Stable LatentMoE 将路由专家扩展至 896、每 token 激活 16。所有上述工作的稀疏红利都以“激活权重可被快速访问”为前提；本文不考虑模型侧稀疏性的进一步优化，而聚焦“既定的激活集合如何通过存储层次搬运”这一问题。

2.2 存储层次与带宽建模

Roofline 模型[7]给出了判断瓶颈位于算力还是带宽的经典框架：在带宽受限区（decode 阶段约 1 FLOP/byte），复用是唯一杠杆——但这只回答了“复用值得做”，未回答“复用应落在哪一层介质”。Eyeriss[8] 在加速器层面给出了“慢层读一次、最快层复用”的实证存在性：AlexNet 上 DRAM 访问约 0.0029 次/MAC，即每个权重从 DRAM 读一次、片上复用数百次。本文的定理与该实证方向一致，但把结论推广为存储层次上任一数据项的通用下界。

2.3 LLM 推理的缓存、预取与调度

vLLM/PagedAttention[9] 用分页缓存消除 KV 缓存碎片，可视为“让复用尽量落在快层”在 KV 尺度上的实现。FlightLLM[10] 针对 FPGA 部署提出 always-on-chip decode，把 decode 权重复用约束在片上。CXL-SpecKV[11] 用 CXL 内存池、预测预取与冷热分层缓解 KV 缓存带宽墙，其活集超容量时的预取/驱逐正是本文定理“不在场情形”的标准处置。FastKV[12] 通过两阶段 prefill 与逐层 KV 保留率解耦压缩与算力，同样以“只保留必要数据于快层”为原则。上述工作均隐含“慢层只应被读一次、复用应在快层”这一工程直觉，但未见将其显式化为可回查的下界定理；本文补上这一形式化层。

3 慢介质读一次：定理与证明

3.1 定义

设存储层次由 N 层介质构成，按单次字节访问代价单调上升排序： M_1 （最慢，代价最高） $\rightarrow M_2 \rightarrow \dots \rightarrow M_N$ （最快，代价最低）。对数据项 d ，被访问（复用）总次数 $R \geq 1$ ；记 R_i 为 d 从介质 M_i 被读取的次数（ $i=1, \dots, k$, M_1 最慢）。

参与路径：定理只对 d 实际穿越的介质下结论。若某介质物理上更快、但 d 从不进入它（如板上的 SDRAM 数据不进、或仅局部进入），它不在 d 的参与路径上，不进求和范围。

3.2 定理

定理 1（慢介质读一次）：设数据项 d 被复用 $R \geq 1$ 次，且复用的实际发生位置是 d 能到达的最快介质 M_k 。则对任意 $i < k$ ，恒有

$$R_i \geq 1,$$

且该下界同时可达：存在一个读取调度，使 $R_i=1$ 对所有 $i < k$ 同时成立，且其余 $R-1$ 次全部落在 M_k 上。

推论：若复用发生在最快层 M_k ，则各慢层读取次数总和的最小值等于各慢层恰读一次；使该最小值达成的调度，同时是慢访问代价最小的调度。

3.3 证明

第 1 步（信息守恒下界，无条件）： d 若从未被从 M_i （ $i < k$ ）读入，则 d 不可能到达 M_{i+1} 及以上层次，更不可能到达 M_k 被复用——数据只能逐层向上搬移，不存在跳过 M_i 直达更高层的通路。因此每层 M_i （ $i < k$ ）至少被读一次： $R_i \geq 1$ 。此下界不依赖任何容量假设、不依赖任何具体工作量。
□

第 2 步（代价单调）：介质按访问代价单调排序，层号越大代价越低。任何“多余的”慢读（即越过下界 1 的额外次数）都可被替换为一次更快介质的读取而不增加总代价，因为慢读严格贵于快读。故达到下界（每慢层恰好一次）的调度使慢访问总代价最小。□

第 3 步（可达性）：复用发生在 M_k 上意味着 d 在 M_k 有活集位置， $R-1$ 次复用可全部在 M_k 内完成。 d 到达 M_k 的路径即逐层各读一次（ M_1 一次 $\rightarrow M_2$ 一次 $\rightarrow \dots \rightarrow M_k$ 一次），该调度合法且同时满足所有下界。□

3.4 边界讨论

容量：容量不构成定理的条件。若活集超出 M_k 容量，复用无法全部发生在 M_k ，数据要么在更窄层内做局部复用（liveness 驱逐），要么被重读——这是定理的“不在场”情形（前提不成立），定理不被违反，只不适用。

不参与介质：物理更快、但数据从不进入的介质不在求和范围，其速度与结论无关。

判据唯一性：定理是否在场只取决于一条判据——复用事实是否存在，即 d 是否真的在它到达的最快介质 M_k 上被复用。

4 真机验证

4.1 实验设置

实验对象：Kimi K3 开源权重[1]。作者对权重文件做 safetensors 全量字节扫描，专家语义为 MXFP4 格点、实际落盘约 2.12 bit/weight（含 scale）[13]，单专家 17.55 MB。引擎：k3 x86 真机推理实现，2026-08 冷启动。存储层次：慢盘 sde（源盘，近满、D-state 风险介质、实测约 84~85 MB/s）→ L2 介质 sdd7 → 系统内存 → 计算。运行时统计内建字节级 READ 计数。所有数字来自真机字节流台账[13]，标注行号可逐字节回查。

4.2 观测一：专家段每 token 全量重读

每 token 专家理论载入 = 92 层（MoE）× 16 专家/层 × 17.55 MB/专家 ≈ 25.83 GB/token。引擎实测专家段 READ = 25.83 GB/token，与理论载入逐字节吻合。即引擎在 CACHE HIT 100% 的报告下，仍每 token 从慢盘 sde 全量重读专家权重——“命中”在白板计数上成立，但字节流层面每次都是冷读，与定理“复用应落在更快介质层”的前提相悖。

4.3 观测二：关键数字及速率的两处字节

速率一处，两处字节都在可回查文件里且两值各有出身：84 MB/s 是介质性能刻画的整值（慢盘近满、巨型 O_DIRECT pread 的实测形态），85 MB/s 是 25.83 GB 与 303.58 s 的精确商。本文据实并列、不引入第三个“速率”声称。

表 1 专家段基准台账（冷启动 2026-08）

指标	数值	出处
每 token 专家理论载入	$92 \times 16 \times 17.55 \text{ MB} = 25.83 \text{ GB}$	台账 :246
实测专家段 READ/token	25.83 GB	:325, :327
专家段耗时	303.58 s/token	:327
端到端耗时	324.36 s/token	:325 (total)
端到端占比	$303.58 / 324.36 = 94\%$	:327
等效速率（精确商）	$25.83 \text{ GB} / 303.58 \text{ s} = 85 \text{ MB/s}$	:327
介质刻画速率（碰壁整值）	84 MB/s（D-state 根因刻画）	:224

4.4 观测三：让复用靠近快层的对照实验

定理预测：慢介质读一次的前提是复用必须落在更快层。2026-08-29 真机复查将其工程化验证：把专家全量 distinct 集（约 10,010 个专家 × 17.5 MB ≈ 176 GB）驻留到 L2 介质 sdd7（实测约 419 MB/s，较慢盘快约 5 倍），专家段耗时从 303 s 降至 191.6 s（约 -37%），端到端从 326.5 s 降至 262.8 s。

该实验读数有两个方向性含义：其一，方向与定理一致——把慢盘上的全量重读移到更快介质，显著压缩了“每 token 全量重读”的代价；收益尚未达到定理给出的“约 -90%”上界（trace 推演 25.8 GB → 2.58 GB/token），原因是复用仍未真正落进内存层——每一 token 仍需从 L2 介质 pread 25.83 GB（1786 MB/s 下亦需约 14.5 s），且命中白板不能免除字节层搬迁。其二，判据得到印证——瓶颈不由“算法能否免读”决定，而由“复用发生在哪一层”决定。

4.5 证据层级与限制

第3章定理属逻辑层，其真值不依赖本节任何数字；本节台账属真机层，账实一致、可回查，但只对本实验（该模型、该介质、该负载、该冷启动时序）成立：25.83 GB/token 与 94% 不构成对别的工作量或别的介质的断言。台账中亦如实记录 FAIL/挂死的条目（如 D-state 永久挂起），未选择性剔除负样本。

5 讨论与应用

5.1 工程判据：先问“复用落在哪一层”

对受内存约束的 MoE 推理，本文给出可迁移的判别次序：

- ① 算法能否免读：该数据项是否必须被读取（如专家是否真是路由集合的必要输入）；
- ② 能否缓存复用：读取结果能否在快层驻留并被复用（即定理的在场条件——复用发生在最快层）；
- ③ 落盘位置：若必须慢读，权重是否至少置于参与路径中较快的介质；
- ④ 落盘前压缩：能否先压缩再落盘，减少届时必须搬动的字节。

真机例证中，k3 引擎在第②条失守（命中不落内存、每次仍全量搬迁），因此纵使第①、④条已成立，带宽墙仍占端到端 94%。

5.2 与调度/预取工作的衔接

本文定理不提出新调度器，而是为既有调度工作提供一个可回查的判据与上界。第2.3节所列工作[9-12]都隐式依赖“慢层读一次”直觉；当方案声称“缓存命中”或“预取成功”时，应回到本定理的判据核实字节层是否真的避免了慢层重读——命中率指标与非易失介质上的字节搬迁指标可能互相遮蔽（见4.4观测三）。

5.3 局限性

存储模型假设单向逐层搬移，未覆盖旁路、直接 DMA 到计算侧等非逐层实现路径——“逐层”只是可达性的一个充分构造，而非必要路径。

真机数字来自单一模型、单次冷启动实测，不声明跨工作量恒真；可达性由定理第3步构造保证，与读者是否阅读本文无关。

6 结论

本文把受内存约束 MoE 推理中的“慢介质每 token 全量重读”这一步难墙形式化为可回查的定理：若复用发生在数据能到达的最快介质层，则每个更慢介质恰好被读一次即可同时满足所有复用，且该下界可达、慢访问代价最小。k3 x86 真机台账忠实记录了一个下界未被满足的反例（25.83 GB/token 全量重读、占端到端 94%），及一个部分收敛的方向性对照（专家迁入 L2 介质后 -37%）。对同类工作，本文建议把“复用发生在哪一层介质”作为排查带宽墙的第一判据。

参考文献

- [1] Moonshot AI. Kimi K3: Open Frontier Intelligence. arXiv:2607.24653, 2026.
- [2] Shazeer N, Mirhoseini A, et al. Outrageously Large Neural Networks: The Sparsely-Gated Mixture-of-Experts Layer. ICLR 2017.
- [3] Lepikhin D, Lee H, et al. GShard: Scaling Giant Models with Conditional Computation and Automatic Sharding. NeurIPS 2020.
- [4] Fedus W, Zoph B, Shazeer N. Switch Transformers: Scaling to Trillion Parameter Models with Simple and Efficient Sparsity. JMLR 23(120):1-39, 2022.
- [5] Jiang A Q, Sablayrolles A, et al. Mixtral of Experts. arXiv:2401.04088, 2024.
- [6] Dai D, Deng C, et al. DeepSeekMoE: Towards Ultimate Expert Specialization in Mixture-of-Experts Language Models. ACL 2024:1280-1297.
- [7] Williams S, Waterman A, Patterson D. Roofline: An Insightful Visual Performance Model for Multicore Architectures. Communications of the ACM, 52(4):65-76, 2009.
- [8] Chen Y H, Emer J, Sze V. Eyeriss: A Spatial Architecture for Energy-Efficient Dataflow for Convolutional Neural Networks. ISCA 2016:367-379.
- [9] Kwon W, Li Z, et al. Efficient Memory Management for Large Language Model Serving with PagedAttention. SOSP 2023:611-626.
- [10] Zeng S, Liu J, et al. FlightLLM: Efficient Large Language Model Inference with a Complete Mapping Flow on FPGAs. FPGA 2024.
- [11] Liu D, Yu Y. CXL-SpecKV: A Disaggregated FPGA Speculative KV-Cache for Datacenter LLM Serving. FPGA 2026:56-66.
- [12] Jo D, Song J, Kim Y, Kim J-J. FastKV: Decoupling of Context Reduction and KV Cache Compression for Prefill-Decoding Acceleration. Findings of ACL 2026.
- [13] 作者自建真机字节流台账（k3 x86 冷启动，2026-08），项目内文件：notes/bytelflow-matrix.md.